


Leonardo Novicki Neto

Cientista de Dados | Machine Learning

Curitiba, PR · (41) 99615-8089 · leoneto98@me.com
linkedin.com/in/leonardo-novicki · github.com/leoneto98



Cientista de Dados com Mestrado em Engenharia Elétrica (UFPR) e graduação em Física, atuando em Machine Learning de ponta a ponta, da identificação da oportunidade de negócio ao deploy e à manutenção do modelo em produção. Experiência com modelos preditivos de regressão, classificação e séries temporais aplicados a grandes volumes de dados de sensores, com stack Python, PyTorch e AWS. Gosto de traduzir problemas complexos de operação em soluções analíticas de impacto mensurável, em contato direto com as áreas de negócio.

COMPETÊNCIAS TÉCNICAS

Linguagens	Python, PySpark, SQL (MySQL, Amazon Athena), MATLAB
ML e Deep Learning	PyTorch, PyTorch Lightning, ConvLSTM, ConvGRU, CNN+Attention, LSTM, GRU, XGBoost, Random Forest, regressão, séries temporais, detecção de anomalias, clustering, otimização com algoritmos genéticos, scikit-learn
Visão Computacional	YOLO, YOLOP, OpenCV, segmentação semântica
Cloud e MLOps	AWS (Athena, S3, Glue, Lambda, SageMaker, ECS), Kedro, MLflow, Docker, APIs REST, awswrangler
Dados e BI	Pandas, Polars, ETL, Power BI, Streamlit
Outros	Git, ROS (Robot Operating System), Google Protocol Buffers, metodologias ágeis (daily, sprint planning, sprint review)

EXPERIÊNCIA PROFISSIONAL

Rumo Logística

Cientista de Dados, Inteligência de Dados

Ago 2024 – Ago 2026
Curitiba, PR

Ingressei pelo programa Talento Inovação (IEL) para mestres e fui internalizado em abril de 2025.

- Elevei a precisão de **55% para 95%** e a sensibilidade de **39% para 60%** na previsão de interdições de via por bitola aberta, frente ao baseline de regressão linear. Isso aumentou a assertividade das manutenções preventivas e evitou o alto custo operacional das interdições.
- Principal desenvolvedor dos modelos preditivos do VIAbiliza, projeto **mapeado pela McKinsey entre os de maior impacto da companhia**. Propus a solução e a implementei de ponta a ponta, os modelos estão hoje em produção.
- Identifiquei na literatura o estado da arte para predição de degradação de geometria de via (LSTM com convolução espacial, aplicada a ferrovias de alta velocidade em Tóquio) e adaptei a solução ao contexto de ferrovia de carga, com pré-processamento, treinamento e critérios de avaliação próprios.
- Desenvolvi e treinei modelos de deep learning para previsão espaço-temporal das irregularidades da via, com arquiteturas ConvLSTM, ConvGRU e CNN+Attention em PyTorch e PyTorch Lightning, além de um mecanismo próprio de fusão de variáveis exógenas (embeddings + concatenação no eixo de canais).
- Resolvi o desalinhamento geográfico entre passagens do vagão instrumentado, um problema conhecido do setor e até então sem solução na companhia, com um algoritmo que alinha **mais de 99%** dos dados e viabilizou toda a modelagem preditiva subsequente.
- Construí um algoritmo de detecção de anomalias, baseado apenas em medidas estatísticas, para identificar picos de medição nos dados do vagão instrumentado. Ele separa leituras inválidas ou fisicamente impossíveis antes da modelagem, o que era essencial num sinal bruto e ruidoso.
- Desenvolvi um detector de defeitos de via a partir do canal de crosslevel, com análise espectral do sinal (PSD por Welch em janelas deslizantes e decomposição wavelet) para isolar as faixas de comprimento de onda associadas a lastro contaminado e a defeitos em dormentes. Fundamentado na literatura científica da área e desenvolvido internamente com os dados do vagão instrumentado, o score resultante passou a alimentar o ConvLSTM como variável exógena.
- Arquiteteei e implementei a pipeline de dados e ML em Kedro: do ETL no Amazon Athena à geração de datasets no S3, treinamento com rastreamento de experimentos em MLflow e inferência em produção, parametrizada por variável-alvo e capaz de comparar múltiplos modelos candidatos.
- Deploy e manutenção dos modelos em produção: inferência em batch por pipelines agendadas e serviço containerizado em AWS ECS acionado por outras equipes, com integração e consumo via APIs REST.
- Tratei dados de geometria de via em larga escala, com medições a cada **25 cm ao longo de mais de 1.500 km** e passagens quinzenais nos dois sentidos, fazendo a limpeza, a normalização e a construção das janelas espaço-temporais usadas como entrada dos modelos, com processamento distribuído em PySpark.
- Primeiro projeto: priorizador de manutenção de dormentes, construído de ponta a ponta em cerca de 5 meses, cobrindo ETL, enriquecimento com dados de operação (MTBT e histórico de manutenções), modelo preditivo de degradação da bitola e dashboard em Power BI usado no planejamento estratégico do corredor Rondonópolis/MT a Santos/SP.

- Engenharia de features a partir de múltiplas fontes, entre elas tonelagem transportada (MTBT), defeitos de infraestrutura, indicadores de pico e degradação, interação veículo-via (VTI), chuva, sazonalidade e tipo de dormente, todas transformadas em tensores e incorporadas aos modelos como variáveis exógenas.
- Ajudei a desenvolver os ingestores que passaram a alimentar o AWS Athena: os dados do vagão instrumentado existiam apenas em arquivos .csv, o que inviabilizava qualquer análise mais extensa.
- Conduzi a avaliação comparativa entre regressão linear, modelos baseados em árvores de decisão (Random Forest, XGBoost) e arquiteturas recorrentes.
- Análise de viabilidade de novo sensor embarcado no vagão instrumentado para detecção de levantamento de trilho, gerando os insights que orientaram a decisão de instalação.
- Elaboração da documentação técnica dos projetos e modelos, em atuação colaborativa com times de negócio (Confiabilidade de Via), tecnologia e dados, em rotina ágil com daily, sprint planning e sprint review.

CARISSMA Institute of Automated Driving

Set 2022 – Mar 2023

Pesquisador, bolsista do governo alemão

Ingolstadt, Alemanha

- Desenvolvimento do TWICE Dataset, conjunto de dados público para pesquisa em veículos autônomos com sensores de câmera, radar, LiDAR e GNSS/IMU, sob supervisão dos professores Werner Huber e Eduardo Parente Ribeiro. Trabalho publicado em periódico internacional revisado por pares.
- Responsável pelo labelling de todo o conjunto de dados, feito de forma semiautomática combinando algoritmos de visão computacional (YOLO) com um algoritmo genético.
- Análise e validação com segmentação semântica (YOLOP) para quantificar o simulation-to-reality gap entre os testes reais e seus respectivos gêmeos digitais.
- Processamento, transformação e organização de todo o volume de dados coletado pelos pesquisadores do instituto, publicando-os em formato agnóstico e acessível e desenvolvendo as ferramentas para abrir, visualizar e processar os arquivos. Python como ferramenta principal, junto a MATLAB, ROS e Google Protocol Buffers.

Santa Lúcia Materiais de Construção

Jan 2016 – Set 2022 · Nov 2023 – Ago 2024

Técnico de TI | Atendimento ao Consumidor

Curitiba, PR

- Desenvolvi um sistema de gerenciamento patrimonial com base de dados em SQL (MySQL) e interface gráfica em Python (Tkinter), com telas para alimentar a base e gerar relatórios.
- Instalação e manutenção da rede de computadores e dos sistemas de segurança eletrônica, além de atendimento ao consumidor e assistência administrativa.

FORMAÇÃO ACADÊMICA

Mestrado em Engenharia Elétrica

Mar 2022 – Nov 2023

Universidade Federal do Paraná (UFPR)

Dissertação: *TWICE Dataset: Digital Twin of Test Scenarios in a Controlled Environment*. Disciplinas: Inteligência Artificial Aplicada, Aprendizado de Máquina, Visão Computacional, Sinais e Sistemas, Métodos Avançados em Sistemas Eletrônicos.

Mestrado Sanduíche em Direção Autônoma

Set 2022 – Mar 2023

Technische Hochschule Ingolstadt (THI), Alemanha

Bolsa do governo alemão para executar o projeto de pesquisa do mestrado no CARISSMA.

Bacharelado em Física

Ago 2016 – Ago 2021

Universidade Federal do Paraná (UFPR)

Formado com média 82,17 (escala 0 a 100), sem nenhuma reprovação. Iniciação científica (CNPq) com o Prof. Dr. Cyro Ketzer Saul no desenvolvimento de um supercapacitor, com coleta, análise e tratamento de dados.

PUBLICAÇÕES

- *TWICE Dataset: Digital Twin of Test Scenarios in a Controlled Environment*. International Journal of Vehicle Systems Modelling and Testing (2025). doi.org/10.1504/IJVSMT.2025.147353
- Pré-print (arXiv): arxiv.org/abs/2310.03895
- Página do projeto: twicedataset.github.io/site
- Dissertação completa, no Acervo Digital da UFPR: acervodigital.ufpr.br/handle/1884/87239

FORMAÇÃO COMPLEMENTAR

- Machine Learning Specialization, Stanford University / DeepLearning.AI (Fev a Mar 2024)

IDIOMAS

Português Nativo

Inglês Avançado. Dissertação de mestrado escrita e apresentada em inglês, e 6 meses na Alemanha com comunicação diária no idioma

Espanhol Intermediário